



Porównanie Proxy Loss functions w rozpoznawaniu produktów detalicznych: skuteczność, jakość osadzeń i efektywność obliczeniowa

Autorzy:

Marcin Maciąg Barbara Borkowska

Promotor:

Grzegorz Sarwas

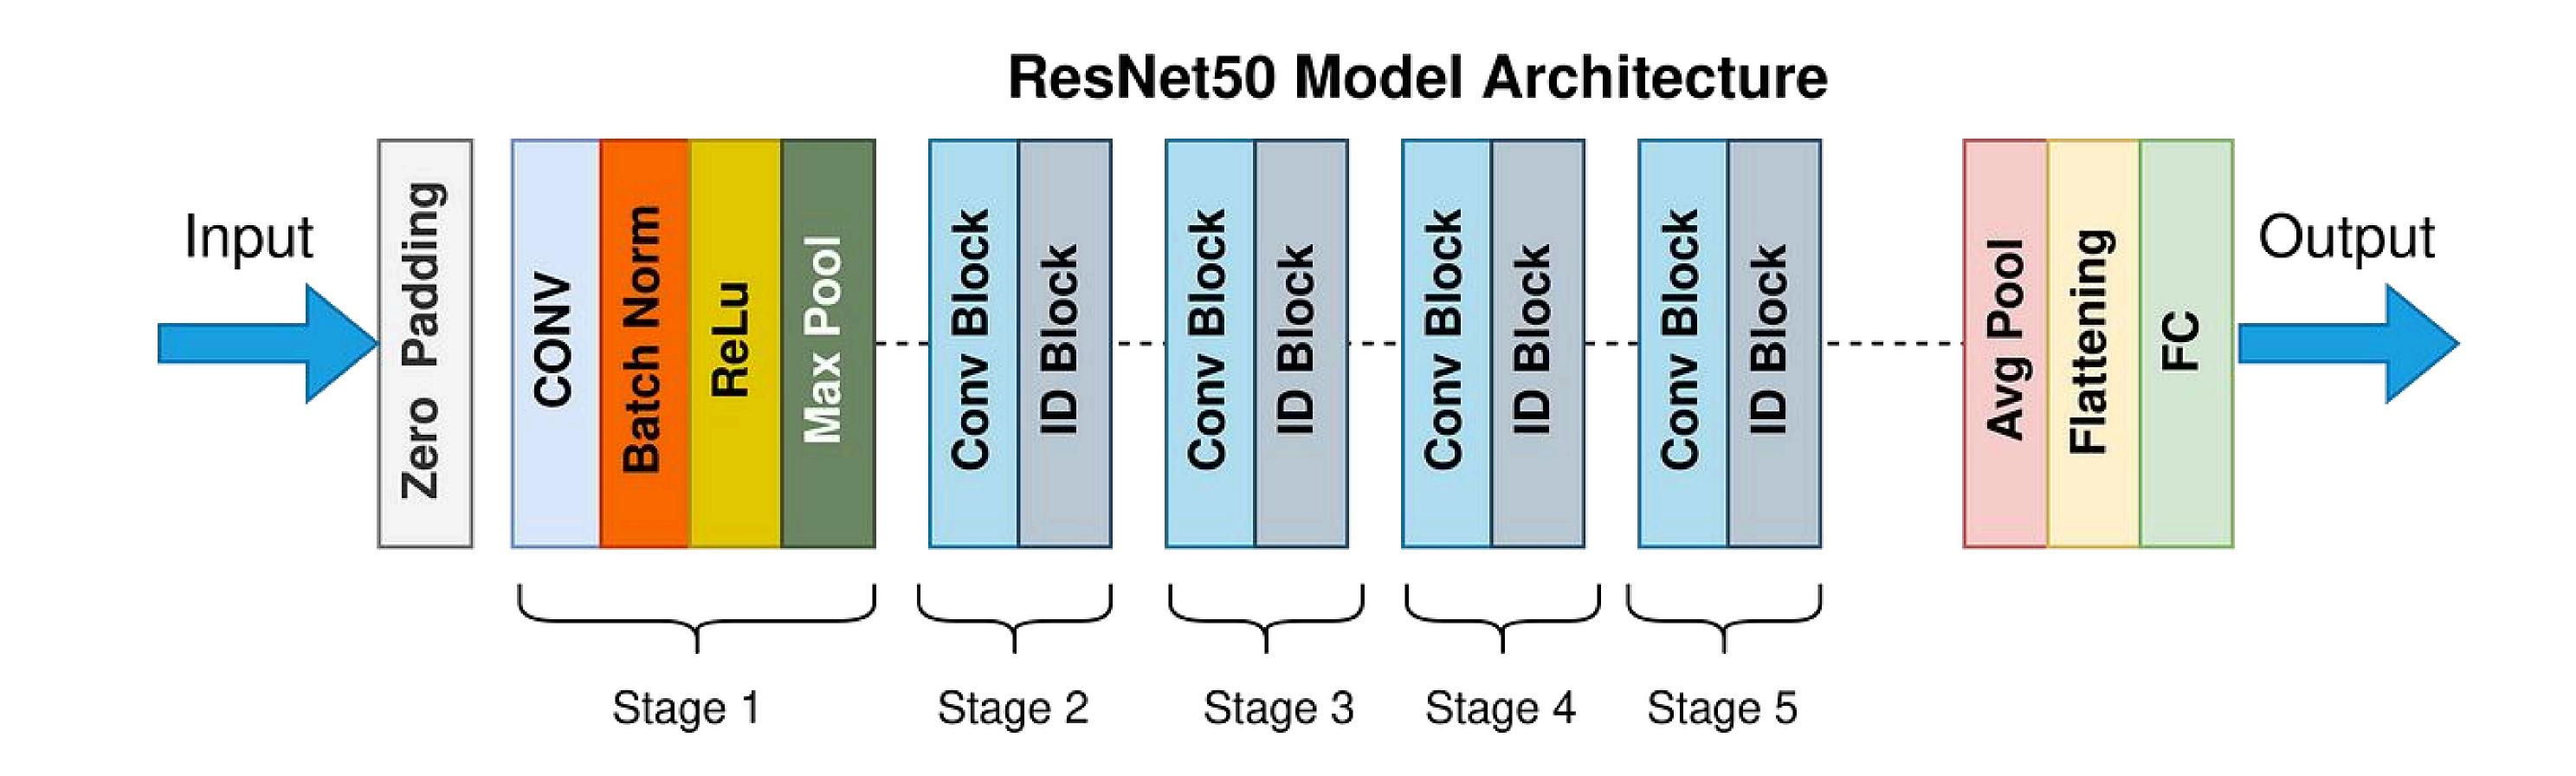
Uczenie maszynowe jest jedną z dziedzin informatyki, Kluczowych technologii wykorzystywaną W rozpoznawanie Obeimuie biznesie. języków, tłumaczenie WZOrców, rozpoznawanie obrazów i mowy, czy rekomendacje produktów. Dynamiczny rozwój tej dziedziny doprowadził do wyodrębnienia nowych podobszarów, takich jak wizja komputerowa czy Tradycyine rozpoznawanie mowy. podejścia opierały się na recznym weiściowych, projektowaniu cech natomiast dzięki uczeniu reprezentacji (representation learning) algorytmy są w stanie autonomicznie pozyskiwać z danych istotne abstrakcje opisujące ich strukturę. Uczenie głębokie idzie o krok pozwalając stopniowe dalei, przekształcanie danych Coraz bardziej abstrakcyjne formy.

Cel badań

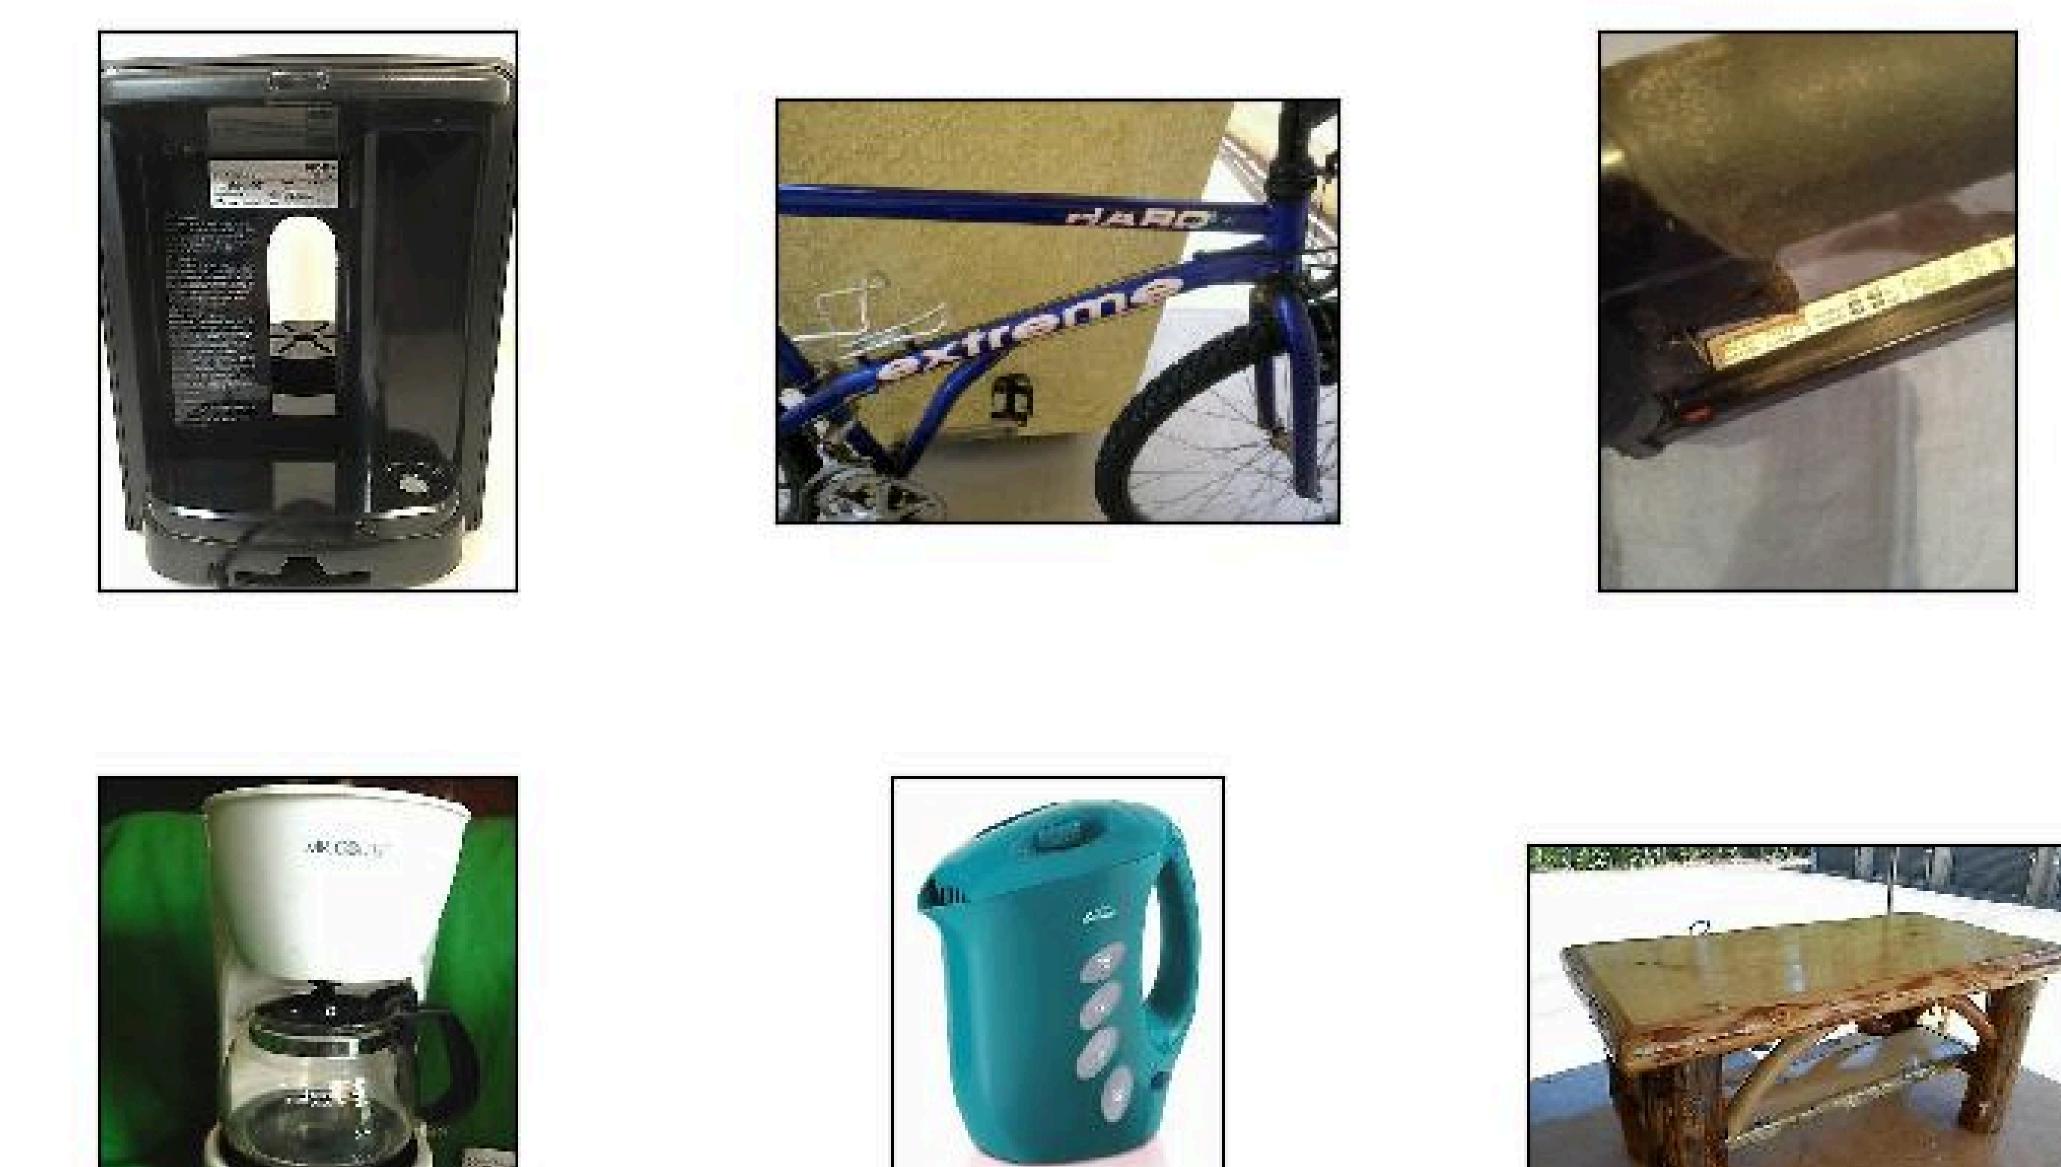
badania koncentrują Nasze obrazów rozpoznawaniu wykorzystaniem Deep Metric Learning. Technika ta ma na celu odwzorowanie danych w przestrzeni embeddingów w próbki sposób, podobne aby znajdowały się blisko siebie, a próbki z różnych siebie. daleko Klas założeniem DML jest Kluczowym odległości maksymalizacja minimalizacia międzyklasowej oraz odległości wewnątrzklasowej.

Architektura i zbiór danych

eksperymentów wykorzystano Do która dzięki architekture ResNet50, połączeniom resztkowym ogranicza zanikających gradientów problem umożliwia uczenie funkcji efektywne Embeddingi o wymiarze 2048 bogata wystarczająco zapewniają przestrzeń reprezentacying do rozróżniania podobnych kategorii produktów.



Duża skala i niezbalansowanie klas w zbiorze Stanford Online Products dodatkowo podkreślają zalety podejścia proxy — upraszczają one obliczenia bez utraty dokładności wyszukiwania.



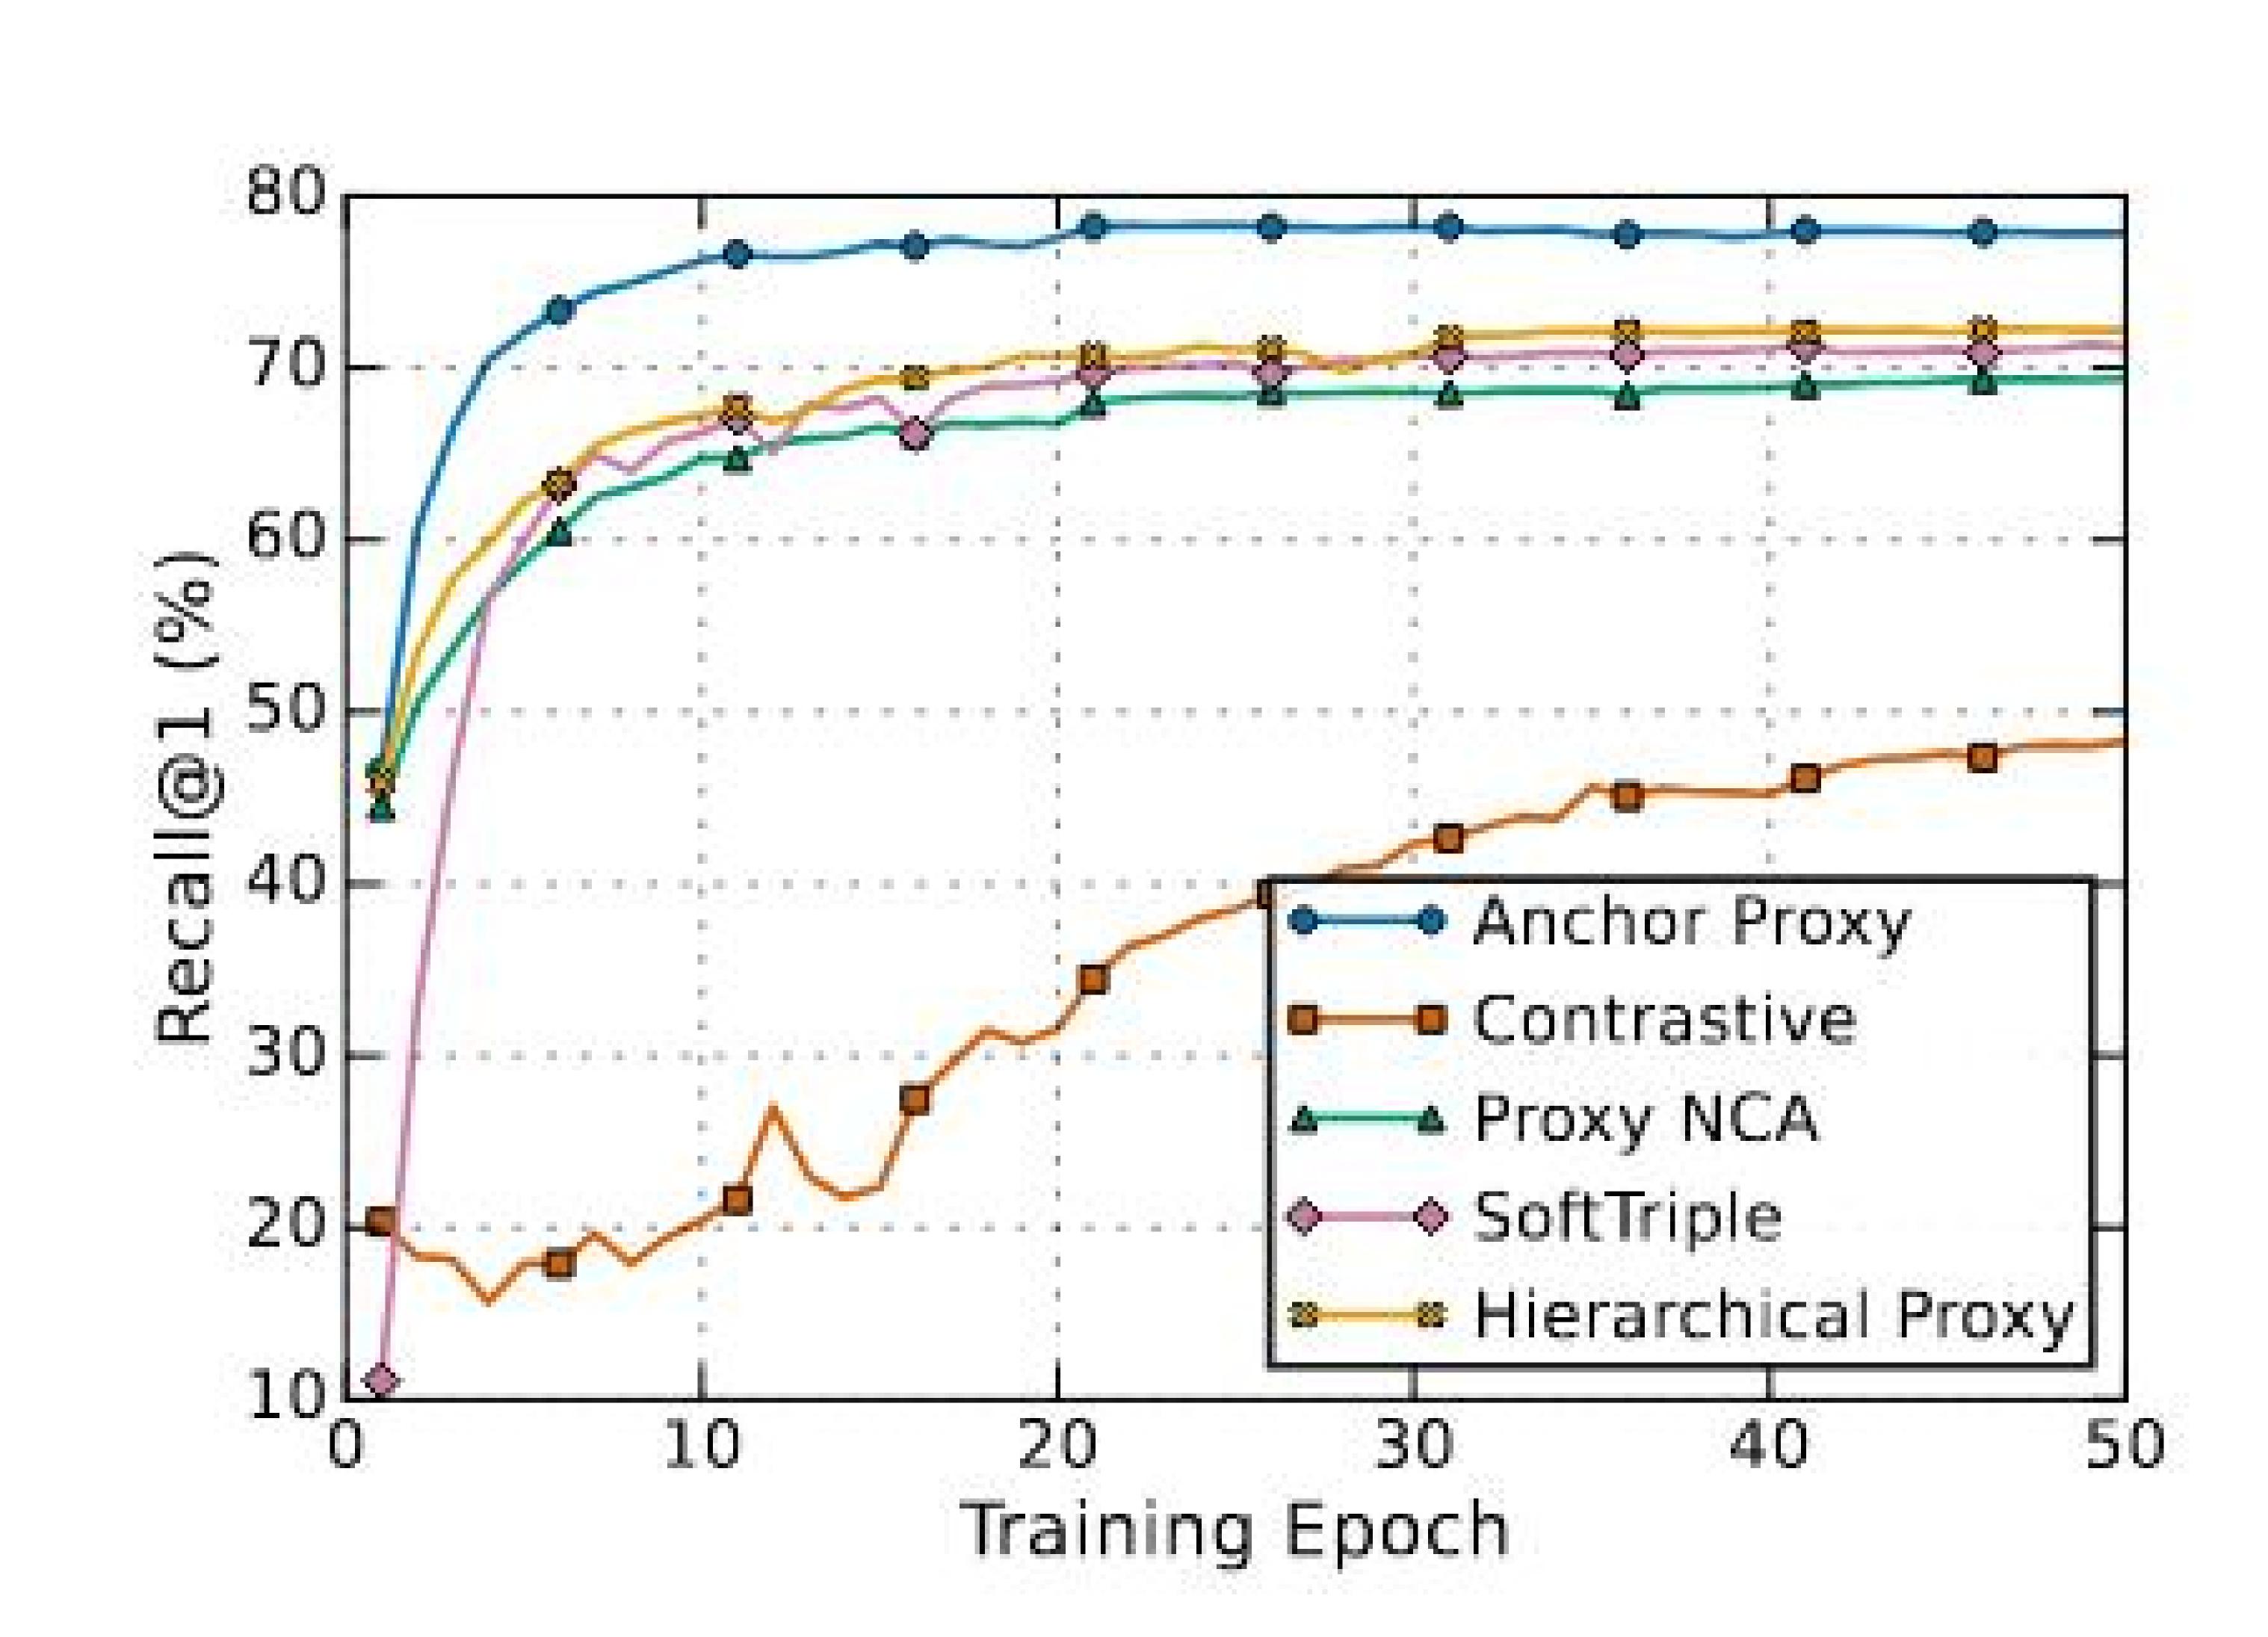






Wyniki eksperymentów

Ostateczne wyniki pokazują wyraźne różnice w skuteczności analizowanych metod. Funkcja Anchor Proxy uzyskała wartości we wszystkich najwyższe metrykach, osiągając 77,60% Recall@1. Najsłabiej wypadła metoda Contrastive, wyniki były znacznie niższe – której różnica względem Anchor Proxy przekraczała 20 punktów procentowych. Co istotne, czas treningu dla większości metod był podobny, z wyjątkiem funkcji Hierarchical Proxy, której uczenie było ponad sześciokrotnie dłuższe. Analiza przebiegu uczenia pokazała, że metody szybciei osiggały Wysoko proxy skuteczność, a Anchor Proxy zapewniała najlepszą stabilność w trakcie całego treningu.



Model	R@1 (%)	R@10 (%)	R@100 (%)	R@1000 (%)
Anchor Proxy	77.60	89.82	95.64	98.49
Contrastive	49.27	66.16	79.99	90.77
Proxy NCA	69.72	83.62	92.45	97.23
SoftTriple	71.19	82.95	90.43	95.86
Hierarchical Proxy	72.18	86.14	94.10	98.04

Funkcie strat

Ewaluacja i metryki

Whioski